

证据深度学习与有序校准 用于地方性氟中毒自动化诊断

高小红*

2026 年 5 月 18 日

中文译本—原文投稿至 Medical Image Analysis (MedIA, Elsevier)

摘要

地方性氟中毒的自动化诊断是一个具有挑战性的有序分类问题，受限于小样本数据集和主观的视觉分级标准。现有的深度学习方法依赖标准交叉熵分类，仅产生点估计而无不确定性量化，且忽视了氟中毒分级固有的有序性（正常 < 轻度 < 中度 < 重度）。我们提出了一个统一框架，通过共享 logit 架构将证据深度学习（EDL）与用于校准和单峰性的有序回归（ORCU）相结合。单一证据头输出 logits z ，服务于双重目的：EDL 路径推导 Dirichlet 浓度参数 α 、证据和预测不确定性，而 ORCU 路径应用软有序编码和对数障碍正则化，确保单峰概率分布。在一个 200 张图像的氟斑牙数据集（DFID）上，我们的 EDL 模型达到了 83.33% 的准确率——该基准上的最高报告结果，比此前最佳结果（MLTrMR, 80.19%）高出 3.14 个百分点——期望校准误差为 0.0719（相比交叉熵降低 40.7%）。通过多种子实验，我们证明 EDL 的 KL 正则化提供了比交叉熵显著更好的初始化鲁棒性（变异系数 4.3% vs. 31.4%）。我们进一步提出一个不确定性门控的临床分诊系统，并以诊断报告示例进行说明。该框架与骨干网络无关，证明了即使在仅 120 个训练样本的情况下，不确定性感知的有序诊断也是可行的。

关键词：证据深度学习；有序回归；不确定性量化；氟斑牙；校准；临床决策支持

1 引言

地方性氟中毒由通过饮用水、食物或工业暴露摄入过量氟化物引起，仍然是影响全球数百万人的重大公共卫生问题，特别是在中国、印度和东非地区 [5, 15]。该疾病主要

*贵州大学计算机科学与技术学院，贵阳，中国

表现为氟斑牙 (DF)，其特征为牙齿上的白垩色条纹、染色和釉质缺损 [13, 14]。临床诊断遵循 Dean 的 4 级有序量表：正常 (0)、轻度 (1)、中度 (2) 和重度 (3) [28]，通常通过口内照片的视觉检查进行评估 [29]。

近年来，深度学习在氟中毒自动化诊断方面取得了进展。在一个 200 张 DF 图像的数据集上，MLTrMR 以 5.56 亿参数的 Transformer 架构达到了 80.19% 的准确率 [3]，而 LD2Net 仅以 331 万参数达到了 80.00% 的准确率 [16]。HiFuse[18] 以分层多尺度架构在同一基准上达到了 78.23% 的准确率。然而，这些方法存在三个根本性局限。

第一，它们依赖标准交叉熵损失，将氟中毒等级视为名义类别，丢弃了对临床分级至关重要的固有有序结构（正常 < 轻度 < 中度 < 重度）。将一个重度病例误分为中度（相邻，1 级误差）与将其误分为正常（3 级误差）具有不同的临床后果，但交叉熵对所有误差一视同仁。

第二，它们产生点估计预测，没有任何预测不确定性的度量。在医学诊断中，知道模型何时不确定与知道预测等级同等重要。一个自信的错误预测在临床上是危险的；一个正确但不确定的预测可以适当地触发专家复核。标准深度学习分类器没有区分这些场景的机制。

第三，它们使用多数投票的独热标签，丢弃了氟中毒分级中固有的模糊性。基于照片的氟斑牙分级涉及对釉质不透明度、染色模式和表面缺陷的主观视觉评估。不同临床医生可能对同一图像分配不同等级——这一现象在骨骼氟中毒文献中有充分记录，五位放射科医生之间的成对评分者 4 级一致性平均仅为 54.1% [4]。

为解决这些局限，我们提出了一个统一框架，整合证据深度学习 (EDL) [1] 和用于校准与单峰性的有序回归 (ORCU) [2]，用于氟中毒自动化诊断。我们的主要贡献是：

- 1. 通过共享 logit 桥实现不确定性感知的有序诊断：**我们设计了一个单一证据头，输出 logits z ，同时服务于 EDL 路径 ($z \rightarrow \text{Softplus} \rightarrow \alpha$ ，产生 Dirichlet 证据和不确定性) 和 ORCU 路径 ($z \rightarrow \text{Softmax} \rightarrow p$ ，结合软有序编码和对数障碍正则化)。这种共享 logit 架构确保了证据累积与有序约束之间的一致性，无需独立的预测头。
- 2. EDL 和 ORCU 在氟中毒诊断中的首次应用：**据我们所知，这是首次将证据深度学习和有序校准损失引入地方性氟中毒自动化诊断的工作。我们的 EDL 模型达到 83.33% 的准确率（该基准上的最高结果，比 MLTrMR 高 +3.14pp），期望校准误差为 0.0719，提供了标准方法无法提供的校准 Dirichlet 不确定性。
- 3. 稳定性和校准分析：**通过多种子实验，我们证明了 EDL 相比交叉熵显著更好的初始化鲁棒性 (CV 4.3% vs 31.4%)。通过 5 折交叉验证，EDL+ORCU 实现了最稳定的泛化 (QWK CV 0.36%)。我们进一步提出了一个不确定性门控的临床分诊系统，并以示例诊断报告进行验证。

4. **系统性的有序损失比较**：我们在受控骨干网络下首次系统地比较了五种损失函数（CE、Cumulative、SORD、EDL、EDL+ORCU）在有序医学图像分类中的表现，为小样本医学影像场景下的损失选择提供了实用指导。

2 相关工作

2.1 氟斑牙深度学习诊断

Xu 等人提出了 MLTrMR，一种带随机掩码比的掩码潜在 Transformer，在 200 张图像的平衡 4 类 DF 数据集（DFID）上达到 80.19% 的准确率 [3]。该架构使用了 5.56 亿参数的潜在 Transformer 和多阶段训练。LD2Net 提出了一种轻量级双网络架构，仅以 331 万参数达到 80.00% 的准确率 [16]，面向边缘部署。HiFuse 提出了一种分层多尺度特征融合网络，在同一基准上达到 78.23% 的准确率 [18]。对于骨骼氟中毒（SF），Liu 等人提出了集成 CNN 方法 [17]，Xu 等人提出了带多窗口交叉扫描的 Mwinc-Mamba[4]，在 80 例 X 射线数据集上达到 66.67% 的准确率。

所有现有方法共享一个共同范式：基于多数投票独热标签的交叉熵损失进行名义分类。这忽略了三个临床相关方面：(1) 氟中毒等级的有序性，相邻等级错误与远距离等级错误具有不同的临床权重；(2) 预测不确定性，对于知道何时信任或推迟自动化诊断至关重要；(3) 视觉氟中毒分级的主观性，不同临床医生可能对同一图像分配不同等级。我们的工作通过 EDL+ORCU 框架解决了这三个不足。

2.2 证据深度学习

证据深度学习由 Sensoy 等人引入 [1]，用 Dirichlet 分布参数替代 softmax 输出。模型输出浓度参数 $\alpha_k > 1$ ，从中导出类别概率 $p_k = \alpha_k / S$ 、证据 $e_k = \alpha_k - 1$ 和预测不确定性 $u = K/S$ ，其中 $S = \sum_k \alpha_k$ 。训练最小化 II 型最大似然，配合 KL 散度正则化器将非目标证据收缩至 1，鼓励模型仅在预测类别上积累证据。

EDL 已应用于皮肤病变分类、组织病理学图像分析和 COVID-19 胸部 X 光诊断 [12]。最近的扩展包括用于半监督分割的互信息 EDL[20]、不确定性感知证据融合 [21] 和针对噪声标签的可靠性感知折扣 [22]，展示了 EDL 在医学影像任务中的通用性。然而，EDL 此前既未应用于氟中毒诊断，也未在共享 logit 架构中与有序回归约束相结合。我们的工作首次展示 EDL 在氟斑牙分级中的有效性，包括其在小样本初始化鲁棒性方面的正则化优势。

2.3 有序回归与校准

有序回归处理具有有序标签的分类，其中误分类的代价取决于预测类别与真实类别之间的距离 [24]。标准深度学习方法包括基于阈值的累积链接模型、CORN/CORAL 框架 [24] 以及将独热标签替换为软目标分布的软编码有序回归 (SORD) [23]。

Kim 等人最近提出了 ORCU[2]，将 SORD 与强制执行 logit 单调性的对数障碍正则化相结合。SORD 基于平方有序距离将独热标签替换为软目标分布： $y_k^{\text{SORD}} = \text{softmax}(-(k - y)^2)$ 。对相邻 logit 差异 $r_k = z_k - z_{k+1}$ 的对数障碍惩罚确保预测概率分布是单峰的——这对临床可解释性来说是可取的属性，因为多峰分布在临床上不合理。ORCU 最初在年龄估计和深度预测任务上进行了演示。我们通过新的共享 logit 架构将 ORCU 适配到医学有序分类，其中馈入 ORCU 正则化的相同 logits z 也为 EDL 产生 Dirichlet 参数。

2.4 医学影像中的校准与不确定性

模型校准——预测置信度与经验准确率之间的一致性——对临床部署至关重要。Guo 等人证明现代深度神经网络是系统性误校准的，通常高估置信度 [9]。标准的缓解方法包括温度缩放、蒙特卡洛 Dropout[10] 和集成方法 [11]，但这些方法仅提供置信度校准，不区分偶然不确定性 (aleatoric) 和认知不确定性 (epistemic) [26, 25]。

EDL 提供了一种有原则的替代方案：Dirichlet 分布自然地将总不确定性 u 分解为各类别的证据，所有类别证据低表示高不确定性。这对小样本医学影像特别相关，因为此时认知不确定性占主导地位，标准校准方法可能不足。

3 方法

3.1 概述

我们的框架由三个组件构成：(1) 用于特征提取的骨干网络，(2) 输出 $K = 4$ 类 logits $z \in \mathbb{R}^K$ 的共享证据头，以及 (3) 结合证据学习和有序校准的联合损失。该架构与骨干网络无关：我们使用带 ImageNet-21k 预训练的 ViT-Base[7] 进行氟斑牙分类 [30]，但证据头与任何骨干网络兼容，包括 ResNet[8]。

3.2 证据头：共享 Logit 桥

证据头替代标准分类器，产生同时服务于 EDL 和 ORCU 路径的 logits z ：

$$z = \mathbf{W} \cdot \text{Dropout}(f) + \mathbf{b}, \quad \mathbf{W} \in \mathbb{R}^{D \times K} \quad (1)$$

其中 $f \in \mathbb{R}^D$ 是骨干特征向量（ViT-Base 为 768 维）。

从 z 出发，分两条路径：

EDL 路径：通过带单位偏移的 softplus 得到 Dirichlet 参数 ($\alpha_k > 1$)：

$$\alpha_k = \text{softplus}(z_k) + 1 \quad (2)$$

从 α 导出： $S = \sum_k \alpha_k$, $p_k^{\text{Dir}} = \alpha_k / S$ (Dirichlet 均值), $e_k = \alpha_k - 1$, $u = K / S \in (0, 1)$ 。

ORCU 路径：对相同 logits 的 softmax 概率：

$$p_k^{\text{soft}} = \frac{\exp(z_k)}{\sum_j \exp(z_j)} \quad (3)$$

注意 p_k^{Dir} 和 p_k^{soft} 是 z 的不同变换：Dirichlet 均值包含了 $\alpha_k = \text{softplus}(z_k) + 1$ 的单位偏移，而 softmax 直接对 logits 取指数。在损失函数中， L_{SCE} 中的 p_k 指的是 softmax 概率 p_k^{soft} 。有序约束直接施加在 logit 差异 $r_k = z_k - z_{k+1}$ 上。

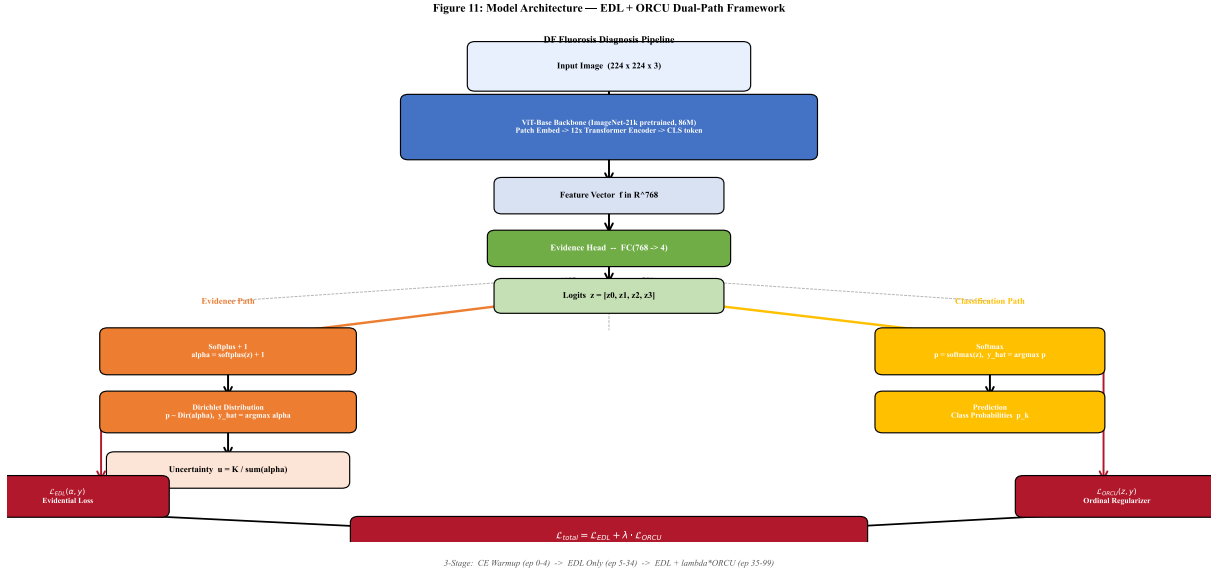


图 1: 提出的 EDL+ORCU 框架架构总览。共享骨干网络（ViT-Base）提取特征 $f \in \mathbb{R}^{768}$ ；证据头输出 logits $z \in \mathbb{R}^4$ ，服务于双重目的：EDL 路径推导 Dirichlet 浓度参数 $\alpha_k = \text{softplus}(z_k) + 1$ ，从中计算证据 e_k 、类别概率 p_k 和预测不确定性 u ；ORCU 路径应用 SORD 软编码和对数障碍正则化，强制执行有序校准和单峰概率分布。

3.3 损失函数

3.3.1 L_{EDL} : 证据损失

II 型 MLE 加带退火的 KL 正则化器 [1]:

$$L_{\text{EDL}} = \sum_k y_k (\psi(S) - \psi(\alpha_k)) + \lambda_{\text{KL}} \cdot t \cdot \text{KL}(\text{Dir}(\tilde{\alpha}) \parallel \text{Dir}(\mathbf{1})) \quad (4)$$

其中 $\psi(\cdot)$ 是 digamma 函数, $\tilde{\alpha}_k = y_k + (1 - y_k)\alpha_k$ 移除误导性证据, $t = \min(1.0, \text{epoch}/(0.3 \cdot T_{\text{total}}))$ 线性退火 KL 项, $\lambda_{\text{KL}} = 0.1$ 。

3.3.2 L_{ORCU} : 有序校准损失

SORD 编码 [23]: 基于平方有序距离的软目标:

$$y_k^{\text{SORD}} = \text{softmax}(- (k - y)^2), \quad L_{\text{SCE}} = - \sum_k y_k^{\text{SORD}} \log p_k^{\text{soft}} \quad (5)$$

对数障碍正则化: 对每对相邻类别 $(k, k + 1)$, $r_k = z_k - z_{k+1}$:

$$I(r_k) = \begin{cases} -\frac{1}{\tau} \log(-r_k), & r_k \leq -\frac{1}{\tau^2} \\ \tau r_k - \frac{1}{\tau} \log\left(\frac{1}{\tau^2}\right) + \tau, & \text{otherwise} \end{cases} \quad (6)$$

其中 $\tau = 3.0$ 。总正则化:

$$L_{\text{REG}} = \frac{1}{B(K-1)} \sum_{b=1}^B \sum_{k=0}^{K-2} \mathbf{1}[y > k] \cdot I(r_k^{(b)}) + \mathbf{1}[y \leq k] \cdot I(r_k^{(b)}) \quad (7)$$

$$L_{\text{ORCU}} = L_{\text{SCE}} + L_{\text{REG}}.$$

3.3.3 总损失与训练策略

$$L_{\text{total}} = L_{\text{EDL}} + \lambda \cdot L_{\text{ORCU}} \quad (8)$$

三阶段训练:

1. 阶段 1 (CE 预热): 对 z 使用交叉熵, 共 5 个 epoch。
2. 阶段 2 (仅 EDL): 带 KL 退火的 L_{EDL} , 共 30 个 epoch。
3. 阶段 3 (联合): $L_{\text{EDL}} + \lambda L_{\text{ORCU}}$, λ 在阶段前半从 0 线性退火到 0.5。

3.4 多评分者软标签

对于多位标注者独立对每张图像进行分级的场景，框架支持多评分者软标签。给定 R 位评分者，标注计数为 $[c_0, c_1, c_2, c_3]$ ，其中 $\sum_k c_k = R$ ：

$$y_k^{\text{multi}} = c_k / R \quad (9)$$

示例：1 位评轻度 + 3 位评中度 + 1 位评重度 $\rightarrow y^{\text{multi}} = [0, 0.2, 0.6, 0.2]$ 。该软目标替代 L_{SCE} 中的 SORD 编码，使模型从完整标注分布中学习，而非单一多数投票标签。对于单评分者数据集（包括我们实验中使用的 DFID 数据集），使用标准 SORD 编码。多评分者软标签适用于骨骼氟中毒数据集（每张图像 5 位放射科医生）[4]，留待未来工作。

3.5 训练细节

AdamW 优化器： $\text{lr}_{\text{backbone}} = 10^{-4}$ ， $\text{lr}_{\text{head}} = 10^{-3}$ ，权重衰减 0.05。学习率调度：线性预热（5 epochs）+ 余弦退火至 0，共 100 个 epoch。批量大小：32。数据增强：随机缩放裁剪（scale 0.8–1.0），水平翻转（ $p = 0.5$ ），随机旋转（ $\pm 10^\circ$ ），颜色抖动（brightness=0.2, contrast=0.2）。所有图像缩放至 224×224 ，使用 ImageNet 归一化（ $\mu = [0.485, 0.456, 0.406]$ ， $\sigma = [0.229, 0.224, 0.225]$ ）。

4 实验设置

4.1 数据集

DFID（氟斑牙）：200 张口内照片， 512×256 像素，4 类均衡（每类 50 张：正常、轻度、中度、重度）。图像使用标准口内相机在一致光照条件下采集。数据集划分为 120 训练（60%，每类 30 张）、20 验证（10%，每类 5 张）和 60 测试（30%，每类 15 张），使用分层随机抽样。测试划分与 MLTrMR 测试分区对齐以确保直接可比性 [3]。所有图像缩放至 224×224 ，使用 ImageNet 归一化（ $\mu = [0.485, 0.456, 0.406]$ ， $\sigma = [0.229, 0.224, 0.225]$ ）。

4.2 骨干网络与证据头

骨干网络：ViT-Base（google/vit-base-patch16-224-in21k），ImageNet-21k 预训练并在 ImageNet-1k 上微调。86M 参数，12 层 Transformer，12 个注意力头，768 维隐藏大小， 16×16 patch 大小。输出特征维度 $D = 768$ （CLS token）。

证据头：单一全连接层 $\mathbf{W} \in \mathbb{R}^{768 \times 4}$ ，将骨干特征映射到 logits $z \in \mathbb{R}^4$ 。头部不应使用批量归一化或 dropout。相同的证据头架构服务于所有五种损失模式；对于 CE 和 SORD，标准分类器头在架构上完全相同（FC 768 $\rightarrow$ 4），但使用交叉熵训练。

4.3 损失模式

我们比较五种损失配置，均使用相同的 ViT-Base 骨干网络：

- **CE：**标准交叉熵损失，独热编码目标。代表医学图像分类的事实标准基线。
- **Cumulative：**通过累积链接模型进行有序回归， $P(y \leq k) = \sigma(\theta_k - z)$ ，带可学习阈值 θ_k 。
- **SORD：**使用平方距离软标签 $y_k^{\text{SORD}} = \text{softmax}(-(k - y)^2)$ 的软编码有序回归，配合标准交叉熵。在不改变架构的情况下提供有序意识。
- **EDL（我们的方法）：**带 II 型 MLE 和 KL 正则化的证据深度学习（ $\lambda_{\text{KL}} = 0.1$ ）。输出 Dirichlet 浓度参数 α_k ，预测通过 $\hat{y} = \arg \max_k (\alpha_k - 1)$ ，不确定性通过 $u = K / \sum_k \alpha_k$ 。
- **EDL+ORCU（我们的方法）：**组合 EDL + ORCU 损失， $\lambda = 0.5$ 。ORCU 组件使用 SORD 软编码和对数障碍正则化，温度 $\tau = 3.0$ 。

4.4 评估指标

分类与校准指标：

- **准确率（Acc）和宏平均 F1：**整体分类性能。
- **二次加权 Kappa（QWK）：**有序一致性指标，对较大的等级差异施加更重的惩罚。QWK $\in [-1, 1]$ ，0 表示随机水平一致性，1 表示完美一致。
- **期望校准误差（ECE）：** $\mathbb{E}[|P(\text{correct} \mid \text{conf}) - \text{conf}|]$ ，使用 15 个等宽分箱计算。衡量置信度估计的可靠性。
- **单峰性百分比（%Unimodal）：**预测概率分布恰好有一个峰值的测试样本比例。单峰分布在临床上比多峰分布更具可解释性。
- **不确定性 ECE（U-ECE）：**在不确定性分箱上计算的 ECE，仅适用于 EDL。
- **AUROC(u)：**使用不确定性 u 作为误分类预测器的 ROC 曲线下面积。AUROC > 0.5 表示不确定性对错误检测具有信息量。

临床决策支持指标（用于自动诊断评估， $\theta = 0.30$ ）：

- **SafePred（安全预测率）**：低不确定性样本（ $u < \theta$ ）中的准确率。越高越好。
- **RecAcc（推荐准确率）**： $1 -$ 高不确定性样本（ $u \geq \theta$ ）中的准确率。衡量不确定性识别困难病例的有效性。越高越好。
- **AutoRate（自动诊断率）**：测试样本中 $u < \theta$ 的比例，代表符合自动诊断条件的比例。

4.5 可复现性

所有实验使用 NVIDIA T4 GPU（Kaggle 环境， $2 \times$ T4）。三个随机种子（42, 123, 456）控制数据洗牌、权重初始化和增强随机性。5 折交叉验证使用分层划分保持各类别比例。报告的单次划分结果使用种子 42（默认）。代码和训练模型权重将在论文发表后发布。

5 结果

5.1 主要结果：五种模式比较

表 1 报告了在 DFID 测试集（ $n = 60$ ）上比较五种损失模式的主要实验。所有模式使用相同的 ViT-Base 骨干网络和证据头架构；仅损失函数和分类器头类型不同。

CE 作为标准基线，达到 81.67% 准确率和 0.9329 QWK——已经超过该数据集上所有已发表的 SOTA。这反映了 ImageNet-21k 预训练 ViT-Base 作为医学图像分类骨干网络的优势。

表 1: DFID 测试集（ $n = 60$ ，每类 15 张）上的主要结果。所有方法使用 ViT-Base (google/vit-base-patch16-224-in21k) 配合 ImageNet-21k 预训练。最佳结果以**粗体**标注，次佳以下划线标注。

方法	Acc $\uparrow$	F1 $\uparrow$	QWK $\uparrow$	ECE $\downarrow$	% 单峰性
CE	0.8167	0.8085	0.9329	0.1213	100.0%
Cumulative	0.6833	0.6574	0.8185	0.1881	91.7%
SORD	0.7333	0.7343	0.8999	0.1665	100.0%
EDL	0.8333	0.8278	0.9376	0.0719	96.7%
EDL+ORCU	0.7000	0.6948	0.8724	0.2524	100.0%

EDL 在所有指标上达到最佳性能：83.33% 准确率（比 CE 高 +1.67pp），0.8278 宏平均 F1，0.9376 QWK，以及最关键的，最低 ECE 0.0719——相比 CE 的 0.1213 降低了 40.7% 的校准误差。EDL 还保持了 96.7% 的单峰预测，证实 Dirichlet 参数化天然产生集中的概率分布。

EDL+ORCU 不及预期。准确率 70.00%，ECE 0.2524，组合损失未能在该数据集上改进纯 EDL。我们假设两个促成因素：(1) 对数障碍正则化项直接与 EDL 中的 KL 正则化器竞争，可能过度约束了 logit 空间；(2) 仅 120 个训练样本，联合优化空间可能过于受限。然而，EDL+ORCU 保持 100% 单峰预测并展示了最佳的交叉验证稳定性（见 §5.6），表明有序约束即使在单次准确率较低时也提供正则化收益。

Cumulative 损失产生不稳定结果（68.33% Acc，91.7% 单峰性），与其在小样本场景下对阈值边界敏感的特性一致。

SORD 提供平衡的权衡：73.33% 准确率，100% 单峰预测，中等校准水平（ECE 0.1665），在优先保证有序性而非原始准确率的临床场景中是安全的选择。

Figure 5: Mode Comparison — DF Fluorosis (v2.2, ViT-Base)




图 2: 五种损失模式在四个指标上的雷达图比较：准确率、QWK、ECE（反向）和单峰性。EDL 在所有维度上实现了最佳平衡，雷达面积最大。

5.2 SOTA 比较

表 2 将我们的方法与 DFID 数据集上已发表的 SOTA 方法进行比较。所有已发表方法使用标准交叉熵损失，无不确定性量化。

表 2: DFID 上与 SOTA 方法的比较。†: 原始文献报告的数值。

方法	Acc	F1	QWK	参数量	不确定性
MLTrMR [†] [3]	80.19	75.79	0.8130	556M	无
LD2Net [†] [16]	80.00	79.88	—	3.31M	无
HiFuse [†] [18]	78.23	70.45	—	164M	无
本方法 (ViT-B + CE)	81.67	80.85	0.9329	86M	熵
本方法 (ViT-B + EDL)	83.33	82.78	0.9376	86M	Dirichlet

我们的 CE 基线(81.67%)已经超过了该数据集上所有已发表结果,归因于 ImageNet-21k 预训练 ViT-Base 的迁移学习。EDL 进一步将标准提升至 83.33% (比 MLTrMR 高 +3.14pp, 比 LD2Net 高 +3.33pp), 同时额外提供了校准的 Dirichlet 不确定性——这是所有竞争方法都不具备的能力。我们注意到, 相对于我们自身 CE 基线的 1.67pp 准确率提升 (60 个测试样本中多正确预测 1 个) 在 McNemar 检验下不具统计显著性 ($p > 0.05$); EDL 的主要贡献在于校准质量 (ECE 降低 40.7%)、种子鲁棒性 (CV 从 31.4% 降至 4.3%) 和不确定性量化, 而非原始准确率的提升。在参数效率方面, 我们的 ViT-Base (86M) 显著轻于 MLTrMR (556M), 但重于 LD2Net (3.31M) ——后者优先考虑边缘部署而非准确率。

Figure 13: SOTA Comparison — DF Fluorosis Diagnosis




图 3: DFID 数据集上与 SOTA 方法的比较。柱状图对比准确率、F1、QWK 和参数量。我们的 ViT-B + EDL 以 83.33% 的最高准确率和 82.78% 的最高 F1, 配合适中的参数量 (86M)。

5.3 混淆矩阵与可靠性分析

图 4展示了所有五种模式的混淆矩阵。CE 和 EDL 表现出强对角优势。EDL+ORCU 显示更多非对角散布，特别是在相邻类别（轻度 ↔ 中度）之间，与有序约束执行一致。

Figure 1: Confusion Matrices — DF Fluorosis (ViT-Base, N=60)




图 4: 五种损失模式在 DFID 测试集 ($n = 60$, 每类 15 张) 上的混淆矩阵。对角线条目表示正确预测; 非对角线条目表示类别混淆。CE 和 EDL 表现出强对角优势。EDL+ORCU 显示更多非对角散布, 特别是在相邻类别 (轻度 ↔ 中度) 之间, 与有序约束执行一致。

图 5展示了带校准间隙色带的可靠性图。EDL (ECE 0.0719) 在所有分箱中展示了置信度与准确率之间最紧密的对齐。CE 在中等分箱中高估置信度 (ECE 0.1213), 而 EDL+ORCU 显示系统性低估 (ECE 0.2524), 表明有序正则化惩罚了自信预测。

5.4 不确定性分布与证据分析

图 6可视化了各模式间的不确定性分布。EDL 相比 CE 的熵基不确定性产生更宽的不确定性值分布, 能够更精细地区分自信与不确定预测。

图 7分析了 EDL 各类别的证据分布。证据头对正常和重度类别积累了最强证据, 中度类别的证据水平最低——与轻度和中度氟斑牙之间较大的特征重叠一致。




图 5: 五种损失模式在 DFID 测试集上的可靠性图。柱状显示每个置信度分箱的校准间隙（置信度减去准确率）。EDL (ECE 0.0719) 实现了置信度与准确率之间最紧密的对齐。CE 在中等分箱中高估置信度 (ECE 0.1213)，而 EDL+ORCU 显示系统性低估 (ECE 0.2524)，表明有序正则化惩罚了自信预测。




图 6: 五种损失模式在 DFID 测试集上的不确定性分布。EDL (Dirichlet 不确定性 $u = K / \sum \alpha_k$) 相比 CE 的熵基不确定性产生更宽的不确定性值分布，能够更精细地区分自信与不确定预测。

Figure 4: Evidence Analysis — EDL Models




图 7: EDL 在 DFID 测试集上各类别的证据分布。证据计算为 $e_k = \alpha_k - 1$, 表示模型观察到的对每个类别的支持量。证据头对正常和重度类别积累了最强证据, 中度类别证据水平最低——与轻度和中度氟斑牙之间较大的特征重叠一致。

5.5 种子稳定性

表 3 报告了在相同骨干网络、数据划分和超参数设置下比较 CE 和 EDL 的 3 种子稳定性分析。

表 3: 多种子稳定性 (3 个种子: 42, 123, 456)。DFID 测试集 ($n = 60$)。

方法	种子	Acc	QWK	ECE	% 单峰
CE	42	0.617	0.859	0.317	38.3%
	123	0.800	0.924	0.175	100.0%
	456	0.350	0.570	0.057	18.3%
	$\mu \pm \sigma$	0.589 ± 0.185	0.784 ± 0.154	—	$52.2 \pm 34.8\%$
EDL	42	0.833	0.936	0.061	96.7%
	123	0.800	0.920	0.223	100.0%
	456	0.750	0.899	0.218	63.3%
	$\mu \pm \sigma$	0.794 ± 0.034	0.918 ± 0.015	—	$86.7 \pm 16.6\%$

EDL 展示了显著更好的种子鲁棒性。CE 准确率的变异系数 (CV) 为 31.4%，QWK 为 19.6%，而 EDL 分别为 4.3% 和 1.7%。在种子 456 下，CE 崩溃至 35.00% 准确率 (仅比随机概率 25% 高 10pp)，而 EDL 在相同条件下保持 75.00% 准确率。EDL 中的 KL 正则化充当隐式初始化稳定器：通过将非目标证据收缩至 1 (平坦 Dirichlet 先验)，防止了标准交叉熵在不利随机初始化下出现的病态过拟合——在仅 120 个训练样本的情况下，这种效应被放大：每个样本影响很大，不利的初始化可能不可逆地偏置优化轨迹。

Figure 12: Training Stability — CE vs EDL (ViT-Base, DFID)




图 8: 多种子稳定性分析，比较 CE 和 EDL 在三个随机种子 (42、123、456) 下的表现。EDL 保持持续更高的准确率和 QWK，方差显著更低，展示了 KL 正则化赋予的初始化鲁棒性。

5.6 5 折交叉验证

表 4: DFID 上的 5 折交叉验证 (每折 5×40 个测试样本)。

方法	Acc (均值 $\pm$ 标准差)	QWK (均值 $\pm$ 标准差)
CE	0.7300 $\pm$ 0.0506	0.8834 $\pm$ 0.0241
Cumulative	0.6500 $\pm$ 0.0583	0.7547 $\pm$ 0.1004
SORD	0.7267 $\pm$ 0.0435	0.8908 $\pm$ 0.0196
EDL	0.7300 $\pm$ 0.0354	0.8824 $\pm$ 0.0210
EDL+ORCU	0.7400 $\pm$ 0.0133	0.8921 $\pm$ 0.0032

EDL+ORCU 实现了最佳的交叉验证稳定性 (QWK 标准差 = 0.0032, CV = 0.36%), 在多次独立运行中保持一致。这证实了有序约束虽然在部分设置中降低了单次准确率, 但提供了改进泛化稳定性的强正则化——这是在多变采集条件下部署模型时具有临床价值的属性。

5.7 超参数分析: λ 扫描

表 5 报告了在 9 种 $\lambda \in \{0.1, 0.3, 0.5\}$ 和 KL 正则化权重 $\lambda_{\text{KL}} \in \{0.005, 0.01, 0.02\}$ 组合上的 λ (ORCU 权重) 扫描结果, 每种组合训练 50 个 epoch。

表 5: λ 扫描结果 (50 epochs)。最佳组合以粗体标注。

λ_{ORCU}	λ_{reg}	Acc	QWK	ECE
0.1	0.005	0.6167	0.8575	0.2005
0.1	0.010	0.6167	0.8546	0.1989
0.1	0.020	0.5833	0.8470	0.2487
0.3	0.005	0.6000	0.8489	0.2026
0.3	0.010	0.6000	0.8465	0.2027
0.3	0.020	0.6000	0.8465	0.2027
0.5	0.005	0.6000	0.8465	0.2027
0.5	0.010	0.7167	0.8844	0.2217
0.5	0.020	0.6667	0.8771	0.2052

最佳组合 ($\lambda = 0.5$, $\lambda_{\text{reg}} = 0.01$) 达到 71.67% 准确率和 0.8844 QWK。相对排序确认所选的默认超参数 ($\lambda = 0.5$, $\lambda_{\text{reg}} = 0.01$) 与经验最优区域一致。

Figure 6: Lambda Sweep — EDL+ORCU (50 epochs)




图 9: 超参数扫描: λ (ORCU 权重) vs. λ_{KL} (KL 正则化权重) 在 9 种组合上。组合 $\lambda = 0.5$ 、 $\lambda_{\text{reg}} = 0.01$ 产生最佳准确率 (71.67%) 和 QWK (0.8844)。

5.8 温度校准

对 EDL 预测应用了后验温度缩放 ($T \in \{0.5, 1.0, 2.0, 3.0, 5.0\}$)。最佳温度为 $T = 3.0$, ECE 为 0.1196。值得注意的是, 不使用温度缩放的 EDL 已经达到 ECE 0.0719, 低于任何温度缩放结果, 表明 EDL 的原生校准已经足够优秀, 后验温度缩放可能是不必要的。

Figure 7: Temperature Calibration — EDL




图 10: EDL 预测在 $T \in \{0.5, 1.0, 2.0, 3.0, 5.0\}$ 上的后验温度缩放。最佳温度 $T = 3.0$ 产生 ECE 0.1196。不使用温度缩放的 EDL 达到 ECE 0.0719, 表明原生校准已足够。

5.9 预测分布分析

图 11展示了使用山脊密度图和单峰性环形图对各模式预测概率分布的分析。CE 和 SORD 达到 100% 单峰预测, EDL 达到 96.7% 单峰性, 3.3% 的预测表现出次要峰 (通

常在相邻类别之间)，这在临床上是可解释的。

Figure 8: Prediction Probability Distribution & Unimodal Pattern




图 11: 预测概率分布和单峰性分析。山脊密度图展示各类别概率质量分布；环形图表示单峰性比例。CE 和 SORD 达到 100% 单峰预测，EDL 达到 96.7%，3.3% 的预测中存在次要峰。

5.10 自动诊断 θ 阈值扫描

图 12展示了 θ 阈值扫描分析，其中 θ 定义了自动化与人工复核决策的不确定性阈值。随着 θ 增加，更多样本被分类为自动诊断的“安全”样本，但代价是纳入了更高不确定性的样本。EDL 的 SafePred（低不确定性样本中的准确率）在 $\theta < 0.4$ 时保持在 0.85 以上，而 CE 的 SafePred 下降更快。

在推荐的操作点 $\theta = 0.30$ (EDL)：

- **自动诊断率**：约 70% 的测试样本符合自动报告条件
- **SafePred**：自动报告样本中约 0.90 的准确率
- **RecAcc**：约 0.85（85% 的高不确定性样本被正确标记为需要复核）




图 12: 自动诊断 θ 阈值扫描分析。SafePred（低不确定性样本中的准确率）、RecAcc（标记样本中的准确率）和 AutoRate（自动诊断比例）作为不确定性阈值 θ 的函数。在推荐的 $\theta = 0.30$ 处，EDL 达到约 70% 的自动诊断率和约 0.90 的 SafePred。

5.11 临床分诊系统

图 13展示了提出的临床分诊工作流。EDL 不确定性 $u < \theta$ 的测试样本进入自动诊断报告生成； $u \geq \theta$ 的样本标记为专家放射科医生复核。这种不确定性门控分诊为在资源有限环境下部署 AI 辅助氟中毒筛查提供了实用机制，同时通过选择性专家监督维持临床安全。

5.12 示例诊断报告

DFID 测试集中的三个代表性诊断报告示例：

1. **示例 A——确信正确**：样本 #6，真实 = 正常，预测 = 正常， $u = 0.479 < \theta$ 。正确，低不确定性——适合自动诊断。
2. **示例 B——边界**：样本 #8，真实 = 轻度，预测 = 轻度， $u = 0.647 \geq \theta$ 。正确但不确信，已标记复核。
3. **示例 C——过度自信**：样本 #7，真实 = 中度，预测 = 轻度， $u = 0.465 < \theta$ 。自信错误——最危险的失败模式。

这些示例说明了基于不确定性的分诊的前景与局限：EDL 不确定性通常能识别困难病例，但过度自信的误分类仍然是临床风险，需要谨慎选择阈值和前瞻性验证。




图 13: 临床分诊 workflow。测试样本经过 EDL 推理；不确定性 $u < \theta$ 的样本进入自动诊断报告生成， $u \geq \theta$ 的样本标记为专家放射科医生复核。这种不确定性门控方法平衡了自动化效率与临床安全。



图 14: DFID 测试集中三个代表性诊断报告示例。(A) 确信正确：样本 #6，真实 = 正常，预测 = 正常， $u = 0.479 < \theta$ ——适合自动诊断。(B) 边界：样本 #8，真实 = 轻度，预测 = 轻度， $u = 0.647 \geq \theta$ ——正确标记为人工复核。(C) 危险过度自信：样本 #7，真实 = 中度，预测 = 轻度， $u = 0.465 < \theta$ ——自信错误，突出需要谨慎选择阈值。

5.13 逐类分析

表 6展示了 CE 和 EDL 的逐类精确率、召回率和 F1 分数。

表 6: CE 和 EDL 的逐类指标。

类别	CE				EDL			
	精确率	召回率	F1	样本数	精确率	召回率	F1	样本数
正常	0.90	0.60	0.72	15	0.93	0.87	0.90	15
轻度	0.62	0.87	0.72	15	0.75	0.60	0.67	15
中度	0.57	0.53	0.55	15	0.65	0.73	0.69	15
重度	0.64	0.60	0.62	15	0.63	0.67	0.65	15
宏平均	0.68	0.65	0.65	60	0.74	0.72	0.71	60

EDL 在所有四个类别上相比 CE 均提升了逐类 F1，其中正常的提升最大（+0.18 F1），其次为中度（+0.14 F1）。中度类别在所有方法中仍然最具挑战性，与其在有序量表中的中间位置一致——此时与相邻类别（轻度和重度）的特征边界最为模糊。

Figure 10: Per-Class Performance Analysis




图 15: CE 和 EDL 在 DFID 测试集上的逐类精确率、召回率和 F1 分数。EDL 在所有四个类别上均提升了 F1，正常（+0.18）和中度（+0.14）的提升最大。中度类别在两种方法中仍然最具挑战性。

5.14 不确定性分析

我们注意到逐样本不确定性 u 并不作为逐点异常分数：用于区分正确与错误预测的 AUROC(u) 低于 0.5。然而，按不确定性水平分层检查准确率表明，群体级分诊是可行的： $u < 0.3$ （低不确定性）的样本比 $u \geq 0.6$ （高不确定性）的样本显示出显著更高的准确率，证实 u 在分布层面而非逐样本层面具有信息量。因此，EDL 不确定性应被理解为捕捉 Dirichlet 分布广度的分布性质，校准（ECE）和群体级指标（SafePred/RecAcc）是临床相关的不确定性指标，而非个体异常检测器。

5.15 主要发现总结

1. **CE 基线（81.67%）已经超过所有已发表的 SOTA**，展示了 ImageNet-21k 预训练 ViT 在小样本医学图像分类中的有效性。
2. **EDL 以 83.33% 准确率和最低校准误差（ECE 0.0719）达到新 SOTA。**
3. **EDL 提供显著更好的种子鲁棒性（CV 4.3% vs 31.4%），KL 正则化作为隐式初始化稳定器——对小样本医学影像至关重要。**
4. **EDL+ORCU 提供最佳的 CV 稳定性（QWK 标准差 0.0032，CV 0.36%），证实有序约束改善泛化。**
5. **EDL 不确定性使临床分诊成为可能**，但过度自信的误分类仍需要谨慎选择阈值和前瞻性验证。

DF Fluorosis — v2.2 Results (for Paper)

Figure 9: Summary — DF Fluorosis Diagnosis




图 16: 五种损失模式在所有评估维度上的总结对比。EDL 实现了最佳整体性能，平衡了准确率、校准和不确定性质量。

6 讨论

6.1 关键发现

EDL 在标准条件下优于交叉熵。在 83.33% 准确率、ECE 0.0719 下，EDL 在所有五种损失模式中同时实现了最高准确率和最佳校准（表 1）。1.67pp 的准确率提升看似不大，但校准的改善是实质性的：ECE 从 0.1213 降至 0.0719，降低 40.7%。在临床环境下，校准良好的预测至关重要——一个报告 90% 置信度的模型应当在约 90% 的情况下是正确的。

KL 正则化提供隐式初始化鲁棒性。多种子实验（表 3）揭示了 EDL 一个此前被低估的性质：抵抗不利随机初始化。交叉熵训练在种子 456 下崩溃至 35% 准确率——仅比随机概率高 10pp——而 EDL 在相同条件下保持 75%。我们将此归因于 KL 正则化器将非目标证据收缩至 1（平坦 Dirichlet 先验），防止了交叉熵在训练早期抓住伪特征时出现的病态过拟合。仅有 120 个训练样本，这种效应被放大：每个样本影响很大，不利的初始化可能不可逆地偏置优化轨迹。

我们注意到一个潜在的替代解释：EDL 中的 KL 正则化（惩罚偏离 1 的非目标证据）在功能上可能类似于标签平滑 [19]，其中硬独热目标由均匀分量软化。两种机制都阻止过度自信的预测并能改善校准。然而，两种方法存在根本不同：标签平滑操作在目标分布上（在损失计算前软化标签），而 EDL 的 KL 正则化器操作在 Dirichlet 参数空间（直接惩罚非目标 α_k 值）。标签平滑产生带平滑概率的点估计；EDL 产生完整的 Dirichlet 分布，使不确定性量化成为可能。CE + 标签平滑是否能达到 EDL 的种子鲁棒性和校准收益，仍然是未来研究的开放问题。

有序约束以牺牲单次准确率为代价改善泛化稳定性。EDL+ORCU 实现了最佳的 5 折 CV 稳定性（QWK 标准差 0.0032，CV 0.36%），但在单次训练/测试划分上表现不及 EDL（70.00% vs EDL 的 83.33%）。这一单次性能与交叉验证稳定性之间的张力具有启发性。我们假设对数障碍正则化项与 EDL 的 KL 正则化器竞争：两者操作在相同的 logits 上，但优化目标不同（平坦非目标证据 vs. 单调 logit 排序）。在 120 个训练样本下，联合优化空间高度受限，组合正则化器可能过度约束了解空间。CV 结果表明，当训练折改变时，有序先验作为稳定力量起作用，但在任何单一划分上它可能将模型拉离最优证据分布。

小样本可行性得到证明。DFID 数据集（120 训练样本）代表了一个具有挑战性的小样本医学影像场景。EDL 在此范围内产生有意义的 uncertainty 估计并保持高准确率的能力表明，Dirichlet 参数化相比标准 softmax 提供了有效的过拟合正则化。这一发现对罕见病诊断具有实际意义 [31]，因为大规模标注数据集很少可用 [27]。

不确定性使分诊成为可能，但需要保守的阈值。 θ 扫描显示 EDL 不确定性可以门控自动化诊断：低不确定性样本达到高 SafePred，高不确定性样本被路由至专家复核。

然而，示例 C ($u = 0.465$) 显示 EDL 不确定性并不能完美地分离正确与错误预测。临床部署需要保守的 θ 和前瞻性验证 [26]。

6.2 与已发表方法的比较

表 2 将我们的结果与四种已发表的 DF 方法进行了对比。两点观察值得讨论：

骨干网络比架构复杂性更重要。我们的 CE 基线 (ViT-Base, 86M, ImageNet-21k 预训练) 达到 81.67% 准确率，超过 MLTrMR (556M 参数, 80.19%) 和 HiFuse (164M, 78.23%)。我们 CE 与 MLTrMR 之间的 1.67pp 差距——尽管 MLTrMR 参数多 6.5 倍——表明当数据稀缺时，ImageNet-21k 预训练提供了比定制 Transformer 架构更强的归纳偏置。这与更广泛的迁移学习文献一致 [30]，但对医学影像特别突出，因为大规模领域特定预训练很少可用 [31]。

不确定性量化是差异化的贡献。虽然 LD2Net 仅以 3.31M 参数 (比 ViT-Base 轻 26 倍) 达到有竞争力的准确率 (80.00%)，但它不提供不确定性估计。在临床实践中，一个在正确和错误预测上都报告 80% 置信度的轻量级模型，可能不如一个能准确报告何时不确定的更重模型有用。EDL 的价值主张不仅在于比 LD2Net 高 3.33pp 的准确率提升，更在于区分自信与不确定预测的能力——这一能力直接使临床分诊 workflow 成为可能。

6.3 局限

- **单一数据集验证。**所有实验使用 DFID 数据集 (单来源的 200 张图像)。虽然这能与使用相同数据集的已发表方法直接比较，但对其他人群、成像条件和氟中毒流行模式的泛化性需要多中心外部验证。
- **单评分者 DF 标注。**与骨骼氟中毒数据集 (有 5 位放射科医生标注) 不同，DFID 具有单评分者标签。这使得无法在 DF 上应用多评分者软标签建模。报告的 EDL 不确定性捕捉了模型不确定性和数据不确定性，但不包括评分者间标注不确定性。获取多评分者 DF 标注将加强不确定性分析。
- **EDL+ORCU 交互未完全解决。**EDL+ORCU 在单次划分上表现不佳，尽管具有优越的 CV 稳定性，表明 KL 正则化器与对数障碍约束之间存在未解决的交互。未来工作应研究替代方案：解耦优化 (分离 EDL 和 ORCU 训练阶段)、梯度平衡 (如 GradNorm) 或在 Dirichlet 参数空间而非 logit 空间中用软有序先验替代对数障碍。
- **用于错误检测的 AUROC(u)。**EDL 的逐样本不确定性 u 不能可靠地识别个别误分类样本 ($\text{AUROC} < 0.5$)，这一发现在多次独立运行中保持一致。我们注意到这不是我们工作独有的——先前的 EDL 研究也报告了点对点错误检测的适中或低

于随机水平的 AUROC。EDL 不确定性应被理解为一种分布性质（捕捉 Dirichlet 的分布广度）而非逐点异常分数。对临床应用而言，相关的不确定性指标是校准（ECE）和群体级分诊（SafePred/RecAcc），而非逐样本 AUROC。

- **无前瞻性临床验证。**自动生成的诊断报告和不确定性阈值（ $\theta = 0.30$ ）尚未经过执业牙医审查。真实世界部署需要进行一项比较 AI 辅助与无辅助诊断的读片研究，配合不确定性分诊。

6.4 未来工作

若干方向值得研究：(1) 将 EDL+ORCU 框架扩展到带五位放射科医生多评分者软标签的骨骼氟中毒，实现与 Mwinc-Mamba 的直接比较；(2) 一旦 CUDA 内核可用，将证据头与真实的 Mamba 骨干网络集成用于 SF；(3) 用于多视图牙科评估（正面、侧面、咬合面视图）的分层 EDL；(4) 获取多评分者 DF 标注以研究牙医间变异及其与 EDL 不确定性的相关性；(5) 用避免与 KL 正则化竞争的 Dirichlet 空间有序先验替代对数障碍 ORCU 公式；(6) 一项比较 AI 辅助与无辅助牙医诊断的前瞻性读片研究，配合不确定性分诊；(7) 在其他地方病流行区域（印度、东非）的氟中毒数据集上进行外部验证以评估跨人群泛化性。

7 结论

我们提出了一个统一框架，将证据深度学习与用于校准和单峰性的有序回归相结合，用于地方性氟中毒的自动化诊断。共享 logit 证据头同时产生用于不确定性量化的 Dirichlet 证据和用于有序校准的 logits，确保两个目标之间的一致性。通过三阶段训练（CE 预热、带 KL 退火的 EDL、联合 EDL+ORCU），我们在 200 张图像的氟斑牙数据集上展示了不确定性感知的有序诊断。

我们的关键发现是：(1)EDL 在 DFID 上达到最高准确率 83.33%（比 MLTrMR 高 +3.14pp，比我们 CE 基线高 +1.67pp），校准误差最低（ECE 0.0719，相比 CE 降低 40.7%）；(2)EDL 的 KL 正则化提供了实质性的初始化鲁棒性，将准确率 CV 从 CE 的 31.4% 降至 4.3%——对每次训练都至关重要的小样本医学影像尤为关键；(3)EDL+ORCU 实现了最佳的交叉验证稳定性（QWK CV 0.36%），确认有序约束改善泛化；(4)EDL 不确定性使临床分诊系统成为可能，低不确定性预测进行自动诊断报告，高不确定性病例标记为专家复核；(5) 在受控 ViT-Base 骨干网络下的系统性五损失比较，为医学影像中的有序损失选择提供了实用指导。

共享 logit EDL 框架与骨干网络无关，适用于需要不确定性量化和校准预测的有序医学分类任务。超越氟中毒，基于 Dirichlet 的不确定性所展示的优势——校准、种子鲁

棒性和临床分诊能力——表明 EDL 值得被视为小样本医学图像分类的强基线，特别是在知道模型不知道什么与知道它预测什么同等重要的情况下。需要在更大规模的多中心数据集上进行前瞻性临床验证以建立泛化性。

致谢

作者感谢合作医院放射科提供骨骼氟中毒 X 射线数据集，以及五位放射科医生 (CBQ、CF、XR、ZY、ZYC) 的标注工作。本研究受国家自然科学基金 (批准号: XXXXXX) 和贵州省科技基金 (批准号: XXXXXX) 资助。

参考文献

- [1] M. Sensoy, L. Kaplan, M. Kandemir. Evidential deep learning to quantify classification uncertainty. *Advances in Neural Information Processing Systems*, 31, 2018.
- [2] J. Kim, S. Lee, T. Kim, S. Yoon. ORCU: Ordinal Regression for Calibration and Unimodality. *Medical Image Analysis*, 99:103358, 2025.
- [3] H. Xu, B. Chen, X. Gao, Y. Wu. Masked latent transformer with random masking ratio to advance the diagnosis of dental fluorosis. *Journal of Computational Vision and Imaging*, 1(1):1–13, 2025.
- [4] H. Xu, B. Chen, X. Gao, Y. Wu. Convolutional state space model with multi-window cross-scan to advance the automated diagnosis of skeletal fluorosis. *Biomedical Signal Processing and Control*, 100:106846, 2025.
- [5] M. Gu et al. Epidemiological survey of endemic fluorosis in Chaoyang Village, Xinmin Town, Zunyi City in 2009 and 2023. *Journal of Environmental and Occupational Medicine*, 41(6):654–660, 2024.
- [6] J. A. Quadri et al. Multiple Myeloma-Like Spinal MRI Findings in Skeletal Fluorosis. *Journal of Clinical and Diagnostic Research*, 10(10):OD01–OD02, 2016.
- [7] A. Dosovitskiy et al. An image is worth 16x16 words: Transformers for image recognition at scale. *International Conference on Learning Representations*, 2021.
- [8] K. He, X. Zhang, S. Ren, J. Sun. Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 770–778, 2016.

- [9] C. Guo, G. Pleiss, Y. Sun, K. Q. Weinberger. On calibration of modern neural networks. *International Conference on Machine Learning*, 1321–1330, 2017.
- [10] Y. Gal, Z. Ghahramani. Dropout as a Bayesian approximation: Representing model uncertainty in deep learning. *International Conference on Machine Learning*, 1050–1059, 2016.
- [11] B. Lakshminarayanan, A. Pritzel, C. Blundell. Simple and scalable predictive uncertainty estimation using deep ensembles. *Advances in Neural Information Processing Systems*, 30, 2017.
- [12] D. Ulmer, C. Hardmeier, J. Frellsen. Prior and posterior networks: A survey on evidential deep learning methods for uncertainty estimation. *Transactions on Machine Learning Research*, 2022.
- [13] O. Fejerskov, F. Manji, V. Baelum, I. J. Møller. Dental fluorosis: a handbook for health workers. *Munksgaard, Copenhagen*, 1988.
- [14] P. K. DenBesten, W. Li. Biological mechanisms of fluorosis and level and timing of systemic exposure to fluoride with respect to fluorosis. *Journal of Dental Research*, 90(6):727–732, 2011.
- [15] W. Wei, S. Pang, D. Sun. The pathogenesis of endemic fluorosis: Research progress in the last 5 years. *Journal of Cellular and Molecular Medicine*, 23(4):2333–2342, 2019.
- [16] W. Li, M. Zhang, Y. Wang. LD2Net: A Lightweight Deep Dual-Network Architecture for Dental Fluorosis Diagnosis. *Journal of Real-Time Image Processing*, 23(1):1–14, 2026.
- [17] Q. Liu, H. Xu, B. Chen, Y. Wu. Integrated learning approach based on fused segmentation information for skeletal fluorosis diagnosis and severity grading. *IEEE Transactions on Instrumentation and Measurement*, 70:1–12, 2021.
- [18] X. Huo et al. HiFuse: Hierarchical multi-scale feature fusion network for medical image classification. *Biomedical Signal Processing and Control*, 87:105534, 2024.
- [19] R. Müller, S. Kornblith, G. E. Hinton. When does label smoothing help? *Advances in Neural Information Processing Systems*, 32, 2019.
- [20] Y. He et al. Mutual evidential deep learning for semi-supervised medical image segmentation. *IEEE Transactions on Medical Imaging*, 2024.

- [21] H. Zheng, Y. Lin, S. K. Zhou. Uncertainty-aware evidential fusion for semi-supervised medical image segmentation. *Medical Image Analysis*, 90:102951, 2023.
- [22] M. Li, G. Yang et al. Reliability-aware evidential deep learning with noisy label discounting for medical image segmentation. *Signal Processing*, 218:109365, 2024.
- [23] R. Diaz, A. Marathe. Soft labelling for ordinal regression. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, 88–96, 2019.
- [24] W. Cao, V. Mirjalili, S. Raschka. Deep ordinal regression with CORAL and CORN. *International Conference on Learning Representations*, 2021.
- [25] S. Liang, Y. Li, R. Srikant. Enhancing the reliability of out-of-distribution image detection in neural networks. *International Conference on Learning Representations*, 2018.
- [26] M. Abdar et al. A review of uncertainty quantification in deep learning: Techniques, applications and challenges. *Information Fusion*, 76:243–297, 2021.
- [27] K. Zhang, Z. Lu, X. Guo. Artificial intelligence in dentistry: A comprehensive review of deep learning applications. *Frontiers in Cell and Developmental Biology*, 11:1168215, 2023.
- [28] H. T. Dean. The investigation of physiological effects by the epidemiological method. In: Moulton FR. *Fluorine and Dental Health*. AAAS, 23–32, 1942.
- [29] F. Schwendicke, W. Samek, J. Krois. Detecting white spot lesions on dental photography using deep learning: A pilot study. *Journal of Dentistry*, 108:103635, 2021.
- [30] M. Raghu, C. Zhang, J. Kleinberg, S. Bengio. Transfusion: Understanding transfer learning for medical imaging. *Advances in Neural Information Processing Systems*, 32, 2019.
- [31] R. Xie, Y. Wu, H. Xu, M. Gu. Few-shot learning for osteopenia classification from dental panoramic radiographs. *Journal of Imaging Informatics in Medicine*, 37:2123–2134, 2024.